EXAONE-4.0-1.2B
Model Compression

[케로로소대]

김동민, 김성재, 장지수, 주민서

Hackaton Overview

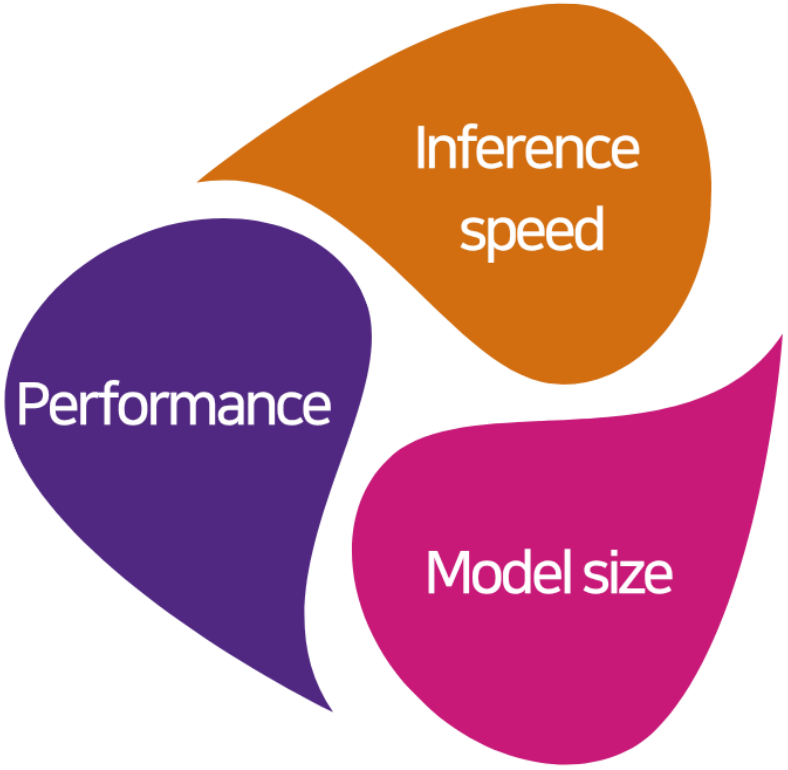

Our Approach

1. Quantization

- W8A8: weight와 activation 값을 모두 INT8로 압축하여 메모리 대역폭 병목 & 연산 병목을 동시에 줄임
- QuantizationModifier: scaling을 통해 activation outlier가 안정적으로 quantization될 수 있도록 처리
- Selective Quantization & Mixed-Precision:
  - 연산량이 많은 linear layer (e.g., attention layer, MLP)에만 quantization 적용
  - 단, 최종 출력층인 lm_head은 quantization 대상에서 제외
  - 최종적으로, INT8 + FP16를 혼합하여 사용

Our Approach

2. KV Cache

- KV Cache는 input context가 길어질수록 VRAM 용량을 매우 크게 차지함
- Key와 Value의 값을 FP8로 변환함으로써 VRAM의 사용량을 줄임 & 메모리 대역폭 병목 완화

Our Approach

3. **Calibration Data**

- calibration data는 quantization 시 변화하는 activation distribution을 조절하는 데 직접적인 영향을 미침
- calibration data selection
  - 모델의 general language capability를 보존
  - 100% private evaluation set에 대응하기 위해, LLM evaluation에 통상적으로 사용되는 evaluation task를 선정
  - general raw text / QA / instruction-following task
    - 모델 내부 지식으로 QA 문제를 해결할 수 있는지 파악: (e.g.) nlpai-lab/kullm-v2
    - 구체적인 지시 사항과 제약 조건을 얼마나 정확하게 이해하는지 측정: (e.g.) google/IFEval

Final Results

1. Quantization
   - inference speed
   - model size
2. KV Cache
   - inference speed
3. Calibration Data
   - performance

1	핸드크림 바른 쥐	쥐순 크림	0.81474
2	케로로소대		0.81414
3	Fukuoka	안정 tm 이승 fe	0.81411

Analysis

EXAONE 4.0 1.2B 구조 분석을 통한 경량화 포인트 도출

EXAONE 4.0: Unified Large Language Models Integrating Non-reasoning and Reasoning Modes

LG AI Research*

EXAONE 4.0 1.2B는 30 layers, hidden size 2048, 32 attention heads, 8 KV heads, 65,536 max positions, SwiGLU, tied embeddings를 쓰는 **소형 온디바이스 지향 모델**

Analysis

EXAONE 4.0 1.2B 구조 분석을 통한 경량화 포인트 도출

구조 분석 결과	반영 내용
Linear 비중 큼	Linear 전체 W8A8
긴 문맥에서 KV 부담 큼	FP8 KV cache
출력 분포 왜곡 민감	lm_head 제외
구조 변경 리스크 큼	PTQ 기반 oneshot calibration 적용
Unified LLM	일반 문장뿐 아니라 QA와 IFEval 스타일 샘플을 함께 넣어, 채점에 중요한 능력 보존

# of layer, hidden size, # of head 등은 세부 hyperparameter는 수정하지 않음으로써 exaone4의 preatrained capability를 최대한 보존

Analysis

EXAONE 4.0 1.2B 구조 분석을 통한 경량화 포인트 도출

Model size	1.2B
d_model	2,048
Number of layers	30
Normalization	QK-Reorder-LN
Non-linearity	SwiGLU
Feedforward dimension	4,096
Attention type	Global
Head type	GQA
Number of heads	32
Number of KV heads	8
Head size	64
Max sequence length	65,536
RoPE theta [52]	1,000,000
Tokenizer	BBPE
Vocab size	102,400
Tied word embedding	True
Knowledge cut-off	Nov. 2024

긴 컨텍스트나 reasoning 모드에서는 시간이 지날수록,
weights보다 KV cache가 실제 메모리 압박의 중심으로 작용 가능

- 구조 레벨: EXAONE이 GQA (Grouped Query Attention)로 KV cache를 줄임
- 시스템 레벨: KV cache를 FP8로 설정해 메모리 대역폭 속도 개선

Analysis

PROMPT: 다음 문장을 한 줄로 요약하세요. 인공지능 기술은 제조 의료 금융 교육 등 다양한 산업으로 빠르게 확산되고 있습니다.

경량화 전 (BEFORE)	경량화 후(AFTER)
인공지능 기술의 산업별 적용 확대를 강조하는 문장입니다.	인공지능 기술이 제조, 의료, 금융 등 다양한 분야에서 활용되며 확산되고 있다.

Analysis

PROMPT: 질문: 7과 8을 곱하면 얼마인가요? 답변:

경량화 전 (BEFORE)	경량화 후(AFTER)
7 × 8 = 56	7과 8을 곱하면 56입니다.

Trial & Error

- VLLM 커스터마이징
  - n-gram과 quantized model을 사용해 speculative decoding을 시도하려고 했으나 n-gram의 명백한 성능 한계로 인해 perfomance-inference speed 사이의 큰 trade-off가 발생
- calibration set
  - 평가 서버 환경의 apply_chat_template=True을 고려해 raw calibration text에 special token (e.g., [|system|], [|user|])을 추가했으나 눈에 띄는 성능 개선이 없었음
- pruning
  - block pruning을 했지만 1.2B의 모델의 작은 크기로 인해 성능 손실이 더 컸음

감사합니다

고용노동부 KEF 한국경영자총협회 대한상공회의소 한경닷컴 DACON LG AI연구원